Tài liệu thuyết minh sản phẩm

Hệ thống truy hồi tài liệu y khoa đa ngôn ngữ — ROAD TO AI 2026, Stage 3
04/11/2026

Thông tin chung

Mục	Nội dung
Đội	Trần Xuân Vũ
Mã nguồn	https://github.com/TranVu2005/r2ai-stage3-submission
Dữ liệu	https://drive.google.com/drive/folders/1NUw099da7rR4zd_j3pg_acTUHjfAH09B (gói và cách dùng ở mục 2.5)
Bài nộp private	5 tệp, liệt kê ở mục 1.7

Bộ hồ sơ gồm:

Tệp	Nội dung
`docs/THUYET_MINH.pdf` (tài liệu này)	Tổng quan hệ thống, dữ liệu, mô hình, mã nguồn, tái hiện
`README.md` (gốc repo)	Cài đặt, tải dữ liệu, lệnh tái hiện
`DATA.md`	Nguồn dữ liệu, gói chia sẻ, dung lượng, cách giải nén
`MODELS.md`	Mô hình, revision, cấu hình suy luận, instruction của reranker
`docs/REPRODUCE.md`	Hướng dẫn tái hiện cho người chấm: clone, tải dữ liệu, chạy, kết quả mong đợi, lỗi thường gặp
`docs/ARCHITECTURE.md`	Bản đồ mã nguồn: module → chức năng

1. Tổng quan hệ thống

1.1 Bài toán

- **Đầu vào:** câu hỏi y khoa tiếng Việt và tập URL tài liệu tiếng Việt, tiếng Trung, tiếng Anh do BTC cung cấp (`links_corpus_vi_en_zh.parquet`, dataset `AIGuruTinix/ViBioMIR`).
- **Đầu ra:** với mỗi câu hỏi, (1) danh sách `doc_id` liên quan (`relevant_docs`) và (2) các đoạn nội dung trích nguyên văn từ chính các tài liệu đó (`relevant_chunks`).
- **Định dạng bài nộp:** một tệp JSON trong ZIP, mỗi phần tử `{id, relevant_docs, relevant_chunks[{doc_id, chunk_text}]}`.

1.2 Phương pháp

Hệ thống là một pipeline **truy hồi dense → xếp hạng lại bằng nhiều reranker → chọn số tài liệu theo F2 kỳ vọng → trích đoạn nguyên văn**. Đặc điểm:

- Không huấn luyện hay fine-tune mô hình; chỉ dùng mô hình open-weight công khai (lớn nhất 4B tham số).

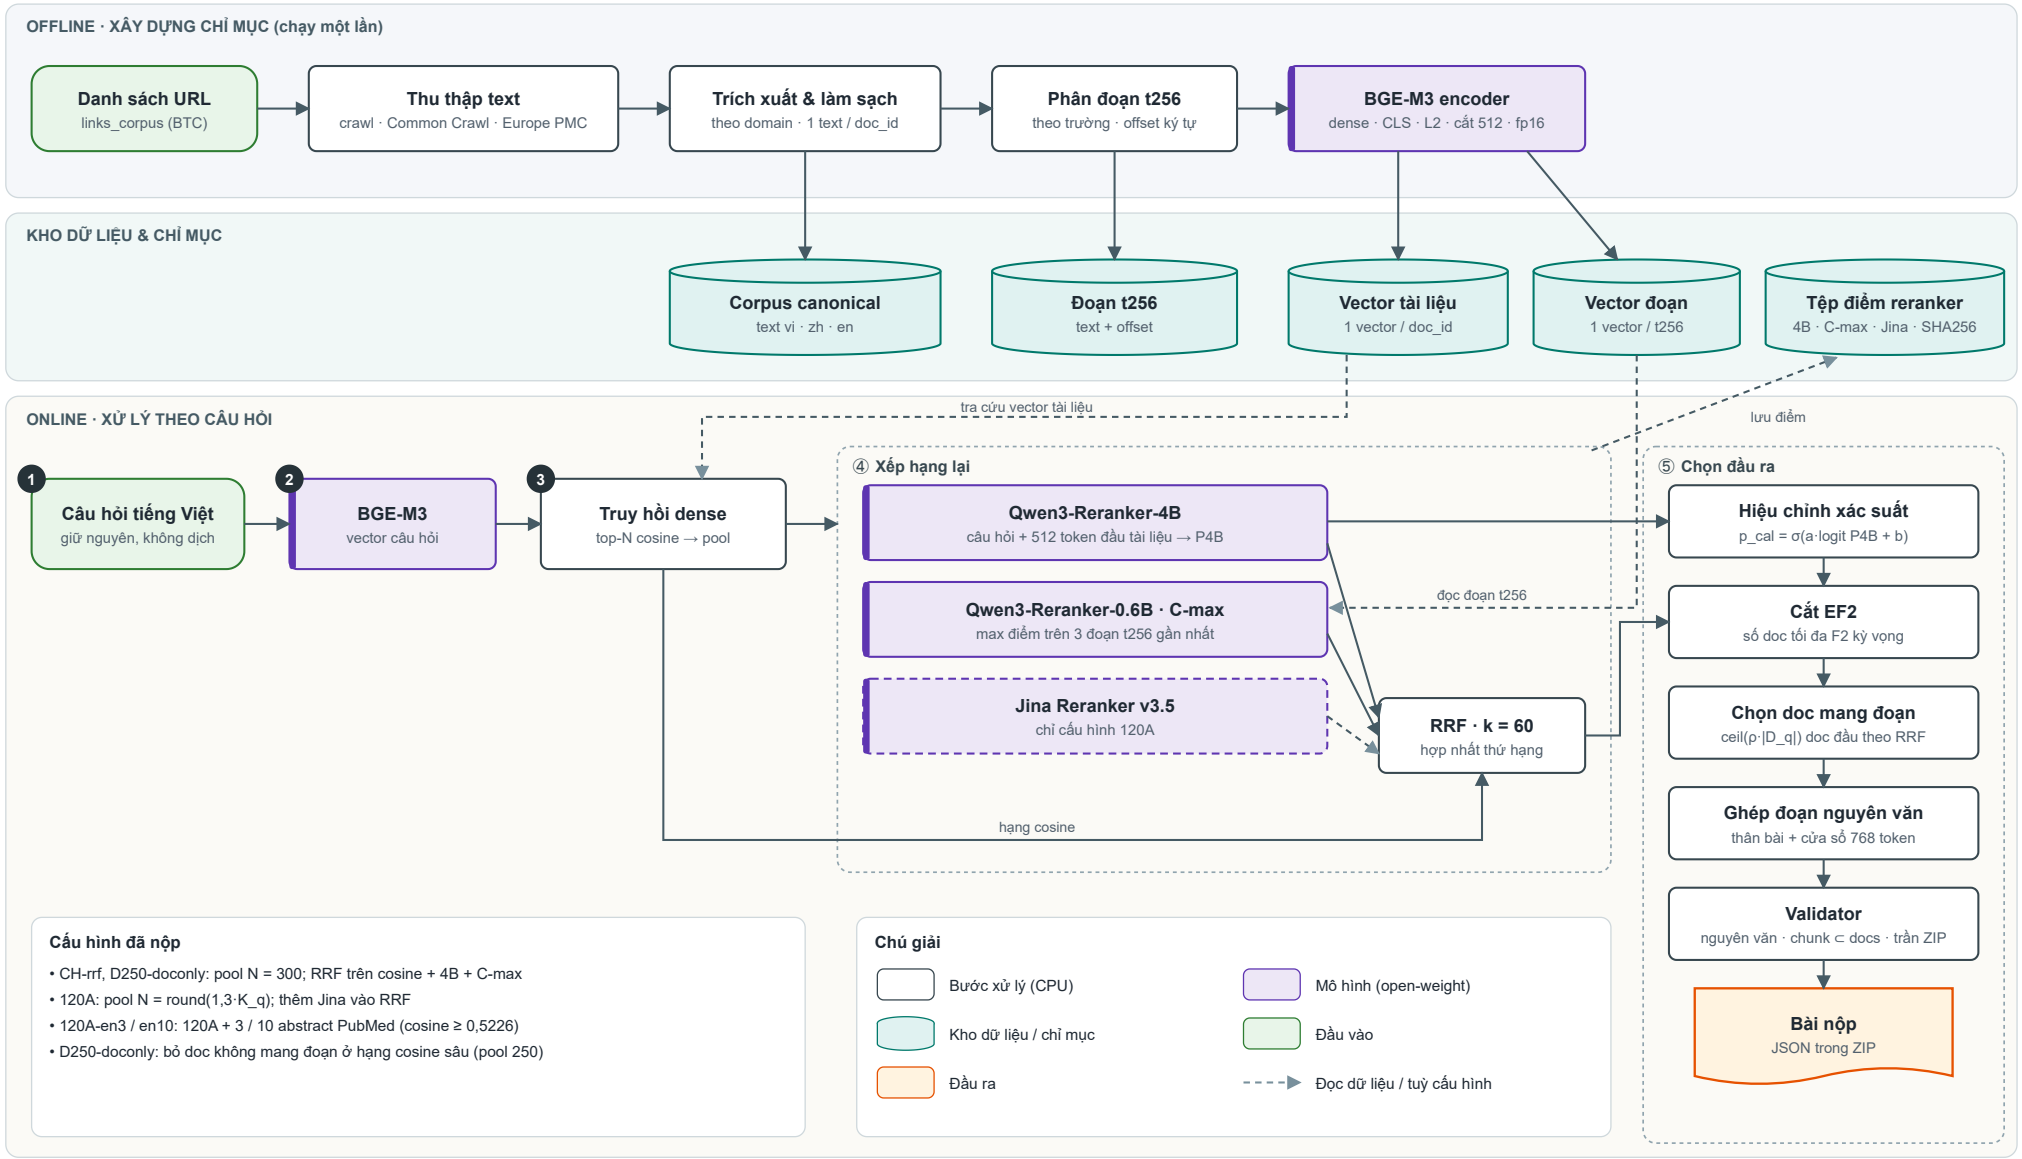
- Không dùng LLM sinh văn bản; mọi đoạn trả về là chuỗi con nguyên văn của tài liệu.
- Bước dựng bài nộp (từ các tệp điểm đã lưu đến ZIP) chạy trên CPU, tất định, và đã được kiểm dựng lại **trùng từng byte** cho cả 5 bài nộp private.

1.3 Kiến trúc và các thành phần

Thành phần	Chức năng	Mã nguồn
Thu thập dữ liệu	Lấy text của các URL trong corpus BTC	`src/vicrawl`, `src/r2ai/crawl`
Trích xuất, làm sạch	Tách tiêu đề / câu hỏi / trả lời / thân bài; chọn một bản text cho mỗi `doc_id`	`src/r2ai/extract`, `src/r2ai/canonical`
Chỉ mục	Phân đoạn t256; nhúng BGE-M3 mức tài liệu và mức đoạn	`src/r2ai/index`
Truy hồi	Nhúng câu hỏi, lấy pool ứng viên theo cosine	`src/r2ai/s29`, `src/r2ai/s37`
Xếp hạng lại	Chấm điểm bằng Qwen3-Reranker-4B, C-max (Qwen3-Reranker-0.6B), Jina; hợp nhất RRF	`src/r2ai/s31`, `s32`, `s35`, `s37`, `notebooks/s36-kaggle-4b-final.ipynb`
Chọn đầu ra	Hiệu chỉnh xác suất, cắt EF2, chọn tài liệu mang đoạn	`src/r2ai/s36`
Ghép đoạn, kiểm tra	Tạo `chunk_text` nguyên văn, validator, đóng gói ZIP	`src/r2ai/s38`
Điều phối	Dựng lại từng bài nộp và kiểm trùng byte với tệp đã nộp	`src/r2ai/reproduce.py`, `scripts/reproduce_*`, `src/r2ai/release.py`

1.4 Luồng xử lý

Kiến trúc hệ thống truy hồi tài liệu y khoa đa ngôn ngữ



Tên module dạng `sNN` (`r2ai.s36`, `scripts/s45/` …) là số đợt phát triển, giữ nguyên để không đổi đường import và config đã ghim; bảng ánh xạ module → chức năng ở `docs/ARCHITECTURE.md`.

1. **Chỉ mục (offline, chạy một lần):** text tài liệu → làm sạch → vector BGE-M3 mức tài liệu (512 token đầu của tiêu đề + thân bài) và vector cho từng đoạn t256.
2. **Truy hồi:** câu hỏi tiếng Việt (giữ nguyên, không dịch) → vector BGE-M3 → lấy N tài liệu có cosine cao nhất làm pool ứng viên.
3. **Xếp hạng lại:** mỗi cặp (câu hỏi, tài liệu) trong pool được chấm bởi các reranker; thứ hạng cuối là hợp nhất RRF.
4. **Chọn đầu ra:** quyết định số tài liệu trả về cho từng câu hỏi, chọn tài liệu nào kèm đoạn trích, ghép đoạn nguyên văn, kiểm tra và đóng gói.

1.5 Xây dựng chỉ mục và truy hồi

- **Vector tài liệu:** BGE-M3 dense, đầu vào `title + body`, cắt 512 token, pooling CLS, chuẩn hoá L2, lưu fp16.
- **Đoạn t256:** cắt theo trường (tiêu đề / câu hỏi / trả lời / thân bài) và đoạn văn, tối đa 256 token, lưu offset ký tự để trích nguyên văn; mỗi đoạn có vector BGE-M3 riêng.
- **Pool ứng viên:** tích vô hướng giữa vector câu hỏi và vector tài liệu trên toàn corpus. Cỡ pool:
  - cấu hình CH-rrf, D250-doconly: 300 tài liệu / câu hỏi;
  - cấu hình 120A: round(1,3 · K_q) tài liệu, trong đó K_q là số tài liệu mà hệ thống thế hệ trước của đội (P1) đã chọn cho câu hỏi đó.
- Khi điểm bằng nhau, thứ tự theo vị trí trong corpus (tất định).

1.6 Xếp hạng lại và chọn kết quả đầu ra

Xếp hạng lại. Mỗi cặp trong pool được chấm bởi:

- **Qwen3-Reranker-4B:** xác suất "liên quan" P4B, đầu vào là câu hỏi + 512 token đầu của tài liệu.
- **C-max:** Qwen3-Reranker-0.6B chấm 3 đoạn t256 gần câu hỏi nhất (theo cosine) của tài liệu, lấy điểm lớn nhất. Thành phần này bắt các tài liệu có đoạn trả lời nằm sâu trong bài.
- **Jina Reranker v3.5** (chỉ cấu hình 120A).
- **Hợp nhất:** Reciprocal Rank Fusion, k = 60, trên các thứ hạng cosine, 4B, C-max (và Jina).

Chọn số tài liệu (cắt EF2).

- Xác suất hiệu chỉnh: $p_{cal} = \sigma(a \cdot \text{logit}(P4B) + b)$.
- Số tài liệu gold kỳ vọng của câu hỏi: $G_q = s \cdot (\Sigma\ p_{cal}$ trên pool + phần đuôi ước lượng ngoài pool).
- Đi theo thứ tự RRF, chọn k tài liệu đầu sao cho F2 kỳ vọng $5 \cdot \Sigma_{i \le k}\ p_{cal,i} / (4 \cdot G_q + k)$ lớn nhất ($k \ge 20$).
- Các hằng số a, b, s và ngưỡng khác là **tham số toàn cục**, chọn trong quá trình phát triển và ghim cố định trong tệp config; không dùng nhãn của từng câu hỏi.

Chọn và ghép đoạn trích.

- Tài liệu mang đoạn trích (carrier): $\text{ceil}(\rho \cdot |D_q|)$ tài liệu đầu theo RRF của mỗi câu hỏi, ρ chọn sao cho tổng số carrier cố định (146,29 / câu hỏi trung bình).
- Nội dung đoạn: thân bài nguyên văn; nếu thân bài dài hơn T = 1.536 token thì thêm một cửa sổ 768 token quanh đoạn t256 có điểm 0.6B cao nhất.
- Nếu ZIP vượt trần 102,6 MB thì giảm T tự động.

Validator (chạy trước khi đóng gói): đủ mọi câu hỏi, `doc_id` thuộc corpus, `chunk_text` là chuỗi con nguyên văn của tài liệu, mọi đoạn thuộc tài liệu có trong `relevant_docs`, tối đa 2 đoạn / tài liệu, ZIP dưới trần dung lượng.

1.7 Các bài nộp private

Tệp nộp	Cấu hình	Kích thước (B)
`1_120A.zip`	120A	99.417.831
`2_D250doconly.zip`	D250-doconly	100.605.161
`3_CHrrf.zip`	CH-rrf	100.651.136
`4_120A-en3.zip`	120A + 3 tài liệu tiếng Anh	100.813.214
`5_120A-en10.zip`	120A + 10 tài liệu tiếng Anh	100.847.665

Cả 5 tệp có trong thư mục `submissions/` của link dữ liệu và trong GitHub Release `v1.0` của repo.

Khác biệt giữa các cấu hình:

	CH-rrf	D250-doconly	120A	120A-en3 / en10
Pool	top-300 cosine	top-300 cosine	top-round(1,3·K_q)	như 120A
Nguồn RRF	cosine, 4B, C-max	như CH-rrf	cosine, 4B, C-max, Jina	như 120A
Số tài liệu	cắt EF2	cắt EF2 trên pool top-250, hợp với các tài liệu mang đoạn của CH-rrf	cắt EF2	120A + 3 / 10 abstract tiếng Anh (cosine ≥ 0,5226)
Đoạn trích	thân bài + cửa sổ 768, T = 1.536	trùng CH-rrf	thân bài + cửa sổ 768, T = 1.536	120A + abstract nguyên văn cho 3 tài liệu tiếng Anh đầu

2. Dữ liệu

2.1 Nguồn dữ liệu

Chỉ dùng text của chính các URL trong corpus BTC. Không thêm tài liệu ngoài danh sách, không có text dịch hay sinh.

Nhóm	Cách lấy text	Số tài liệu
Tiếng Việt, tiếng Trung (đa số)	Crawl trực tiếp theo URL; Common Crawl (WARC, tra theo index, lưu provenance từng tài liệu)	887.151 (corpus canonical)
120ask (tiếng Trung, hỏi đáp)	Crawl trực tiếp từ máy chủ đặt ở nước ngoài	73.000 (9 segment, crawl từ 73.001 URL chưa có text). Corpus BTC có 98.160 URL 120ask: 25.151 đã có text trong corpus canonical, 9 không lấy được text
Pharmacity	Theo hướng dẫn BTC (19/10): lấy từ `www.pharmacity.vn/<slug>.htm`, giữ nguyên `doc_id`	979
Tiếng Anh (PubMed)	Abstract qua Europe PMC theo PMID trong URL	239.771 (chỉ dùng cho 120A-en3/en10)

2.2 Thu thập và làm sạch

- Trích xuất theo domain (bộ chọn riêng cho các trang lớn: tiêu đề / câu hỏi / trả lời / thân bài); trang khác dùng trafilatura.
- Chỉ chuẩn hoá khoảng trắng; không sửa nội dung.
- Mỗi `doc_id` giữ đúng một bản text; quy tắc chọn khi có nhiều nguồn ghi trong `decisions.parquet`.
- Kiểm toàn bộ: `doc_id` thuộc corpus BTC; đoạn là chuỗi con nguyên văn; vector khớp text (79 tệp đầu vào ghim trong `configs/s41-newq-pins.json`).

2.3 Phân đoạn văn bản

- Đoạn chỉ mục t256 (mục 1.5), lưu kèm offset ký tự.
- Đoạn trong bài nộp: thân bài nguyên văn, cộng một cửa sổ 768 token cho bài dài (mục 1.6).

2.4 Lưu ý về tái hiện dữ liệu

Trang web thay đổi theo thời gian nên crawl lại **không** cho kết quả trùng byte. Điểm xuất phát tái hiện là **corpus canonical đã trích xuất** trong gói chia sẻ. Mã crawl và trích xuất có trong mã nguồn để đối chiếu phương pháp.

2.5 Truy cập dữ liệu

Thư mục dữ liệu: https://drive.google.com/drive/folders/1NUw099da7rR4zd_j3pg_acTUHjfAH09B. Trong đó: `data/` (8 gói và tệp `.SHA256SUMS` của từng gói), `submissions/` (5 ZIP bài nộp), `SHA256SUMS`, `data-manifest.csv`, `README_DATA.txt`.

Gói (trong `data/` của thư mục chia sẻ)	Nội dung	Dung lượng	Cần cho
`r2ai-data-canonical.tar`	corpus canonical (text, đoạn, vector)	18,1 GB	mọi bài nộp
`r2ai-data-120ask.tar`	segment 120ask	1,07 GB	mọi bài nộp
`r2ai-runs-inputs.tar`	vector tài liệu và câu hỏi, Pharmacity	2,2 GB	mọi bài nộp
`r2ai-runs-scores.tar`	tệp điểm 4B, C-max, Jina cho các cặp trong pool	0,61 GB	mọi bài nộp (dựng lại không cần GPU)
`r2ai-runs-meta.tar`	manifest, tham số hiệu chỉnh	34 MB	mọi bài nộp
`r2ai-s49-inputs.tar`	`kq_counts.parquet`, `p1_chunks.parquet`, `p1_chunks_chrrf.parquet`	10 MB	120A, 120A-en3/en10, CH-rrf
`r2ai-data-en-pubmed.tar`	abstract PubMed + vector	1,19 GB	120A-en3/en10
`r2ai-submissions.tar`	5 ZIP private + bản tham chiếu	0,70 GB	CH-rrf, D250-doconly (mốc so sánh thứ tự tài liệu)

Cách dùng (đường dẫn trong gói là `data/…`, `out/runs/…`, `submissions/…`, nên mọi gói giải nén vào cùng một thư mục gốc):

```
sha256sum -c SHA256SUMS --ignore-missing      # kiểm toàn vẹn các tệp đã tải
export R2AI_ROOT=/duong/dan/r2ai-root
mkdir -p "$R2AI_ROOT"
for f in data/r2ai-*.tar; do tar -xf "$f" -C "$R2AI_ROOT"; done   # Git Bash, đường dẫn có ổ đĩa: thêm --force-local
```

3. Mô hình sử dụng

Mọi mô hình là open-weight, dùng nguyên checkpoint công khai (không fine-tune, không checkpoint riêng của đội), tải từ Hugging Face theo revision cố định.

Mô hình	Revision	Tham số	Vai trò	Cấu hình suy luận	Giấy phép
`BAAI/bge-m3`	`5617a9f6…`	568M	Nhúng tài liệu, đoạn, câu hỏi; tokenizer đếm token	dense CLS, L2, cắt 512, fp16	MIT
`Qwen/Qwen3-Reranker-4B`	`22e68366…`	4B	Điểm tài liệu P4B; cơ sở hiệu chỉnh p_cal	fp16, cắt 512 token, 2×T4 (Kaggle)	Apache-2.0
`Qwen/Qwen3-Reranker-0.6B`	`e61197ed…`	0,6B	C-max (điểm đoạn), chọn cửa sổ 768	bf16, đoạn t256, top-3 đoạn / tài liệu	Apache-2.0
`jinaai/jina-reranker-v3.5`	`e8a93f33…`	0,6B	Nguồn RRF thứ tư (chỉ 120A)	listwise, bf16, khối ≤ 10 tài liệu xáo theo seed `query_id`, tài liệu cắt 512 token	CC-BY-NC-4.0

- Revision đầy đủ (40 ký tự) và instruction nguyên văn của các reranker Qwen3: `MODELS.md`.
- Tải: `hf download <model_id> --revision <revision>`.
- Không dùng API hay mô hình đóng.

4. Mã nguồn

4.1 Phạm vi

Mã nguồn đầy đủ ở https://github.com/TranVu2005/r2ai-stage3-submission: thu thập và trích xuất dữ liệu, dựng corpus, chỉ mục, truy hồi, chấm reranker, chọn đầu ra, ghép đoạn, validator, đóng gói và các script tái hiện.

- Repo chỉ chứa mã và tài liệu cần cho bài nộp và việc tái hiện; đường dẫn máy thay bằng biến môi trường (mẫu `configs/paths.example.env`).
- Một điểm vào cho tái hiện: `python -m r2ai.reproduce`.
- Bản đồ module → chức năng: `docs/ARCHITECTURE.md`.

4.2 Môi trường và phụ thuộc

- Python 3.12 (`requires-python >= 3.11, < 3.14`).
- Phụ thuộc khai báo trong `pyproject.toml` (extra `[reproduce]` cho tái hiện); phiên bản khoá đầy đủ ở `configs/environment.constraints.txt`.
- Các gói quyết định byte của ZIP: pyarrow 25.0.1, numpy 2.5.3, pandas 3.0.6, polars 1.44.2, transformers 5.18.0, tokenizers 0.23.2.
- torch 2.11.0+cu128: chỉ cần khi chấm reranker hoặc nhúng lại.

4.3 Tệp cấu hình

Cấu hình	Tệp config	Tệp ghim đầu vào
CH-rrf	`configs/s41-private-final.json`	`configs/s41-newq-pins.json`
D250-doconly	CH-rrf + `scripts/s45/public_rebuild.py --depth 250` + `scripts/s45/doc_only.py`	như CH-rrf

Cấu hình	Tệp config	Tệp ghim đầu vào
120A	`configs/s36-handoff-120A-p4b-v3.json`	`configs/s36-handoff-s30-manifest.json`
120A-en3 / en10	120A + `scripts/s48/hedge_on_zip.py`	như 120A + gói `en-pubmed`

5. Hướng dẫn cài đặt và tái hiện

Hướng dẫn từng bước cho người chấm, kèm lệnh kiểm sau mỗi bước, kết quả mong đợi và lỗi thường gặp: `docs/REPRODUCE.md`. Lệnh đầy đủ và các tuỳ chọn: `README.md`. Tóm tắt dưới đây.

5.1 Yêu cầu môi trường

Mức	Phần cứng	Thời gian
A. Dựng lại bài nộp từ tệp điểm	CPU, RAM ≥ 16 GB, ổ trống ≥ 60 GB	khoảng 4 giờ 25 phút cho 5 tệp nộp (`--all`)
B. Chấm lại reranker	GPU: 2×T4 (Kaggle) cho 4B; GPU ≥ 6 GB cho C-max	4B khoảng 15 giờ / 360.000 cặp; C-max khoảng 10 giờ

Đã kiểm trên Windows (Git Bash); Linux chưa kiểm.

5.2 Cài đặt

```
git clone https://github.com/TranVu2005/r2ai-stage3-submission r2ai-stage3 && cd r2ai-stage3
python -m venv .venv && source .venv/bin/activate      # Windows (Git Bash): source .venv/Scripts/activat
e
pip install -e ".[reproduce]" -c configs/environment.constraints.txt \
    --extra-index-url https://download.pytorch.org/whl/cu128
export R2AI_ROOT=/duong/dan/r2ai-root                   # thư mục đã giải nén các gói (mục 2.5)
export HF_HOME=/duong/dan/hf_home HF_HUB_OFFLINE=1      # mô hình theo revision ở MODELS.md
```

5.3 Chạy lại

Mức A: dựng lại các bài nộp private (chỉ CPU):

```
python -m r2ai.reproduce --all                  # 5 tệp nộp, in bảng PASS/FAIL (chỉ cần CPU)
python -m r2ai.reproduce ch-rrf d250-doconly    # hoặc từng tệp: 120a, 120a-en3, 120a-en10; kiểm thêm: 12
0a-nop1
python -m r2ai.reproduce --list                 # các mục dựng được
```

Lệnh tự so mỗi ZIP đầu ra với tệp đã nộp (mục 1.7) và chỉ báo PASS khi ZIP do chính lần chạy này ghi ra và trùng từng byte; mã thoát khác 0 nếu có bài FAIL. Bên dưới, lệnh gọi `scripts/reproduce_public.sh` (CH-rrf, D250-doconly), và `scripts/reproduce_120a.sh` (120A, en3, en10, nop1).

Mức B: chấm lại reranker:

- 4B: chạy `notebooks/s36-kaggle-4b-final.ipynb` trên Kaggle (2×T4) với tệp cặp xuất từ bước truy hồi, rồi nạp điểm về.
- C-max: `scripts/s32/run_score.ps1`, `scripts/s37/run_cmax.ps1` (GPU máy).

Phụ lục: thuật ngữ

Thuật ngữ	Nghĩa
Pool	Tập tài liệu ứng viên của một câu hỏi, lấy theo cosine BGE-M3
P4B	Xác suất liên quan do Qwen3-Reranker-4B chấm
C-max	Điểm lớn nhất của Qwen3-Reranker-0.6B trên 3 đoạn t256 gần câu hỏi nhất
RRF	Reciprocal Rank Fusion: điểm = Σ 1 / (k + hạng) qua các nguồn
p_cal	Xác suất đã hiệu chỉnh từ P4B
EF2	Quy tắc chọn số tài liệu sao cho F2 kỳ vọng lớn nhất
Carrier	Tài liệu được kèm đoạn trích trong `relevant_chunks`
t256	Đoạn chỉ mục dài tối đa 256 token BGE-M3
CH-rrf, D250-doconly, 120A	Tên các cấu hình đã nộp (mục 1.7)
P1	Hệ thống thế hệ trước của đội (18/10/2026)